

Charakterystyka próby. Doświadczenia jednoczynnikowe – analiza wariancji i testy szczegółowe
Weryfikacja hipotez dotyczących jednorodności wielu wariancji rozkładów normalnych
Test nieparametryczny Kruskala- Wallisa

Estymatory punktowe średniej, wariancji i odchylenia standardowego

$$\hat{\mu} = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\hat{\sigma}^2 = \hat{s}^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

$$\hat{s} = \sqrt{\hat{s}^2}$$

Współczynnik zmienności

$$v = \frac{\hat{s}}{\bar{x}} \cdot 100\%$$

Zadanie1 1. W ramach gospodarowania zasobami środowiska przyrodniczego, wykonano pomiary zanieczyszczenia powietrza. Badano poziom stężenia fluoru w mg/m³ na terenie Lubonia w lipcu 2010 roku, jakie występowało tam w związku z działalnością zakładów chemicznych Luvena. Pomiary wykonane zostały przez Wojewódzką Stację Sanitarno-Epidemiologiczną w Poznaniu. Za pomocą pakietu STATISTICA podaj i **zinterpretuj** statystyki opisowe dla poziomu stężenia fluoru w powietrzu w badanym okresie dla Lubonia. Wykonaj histogram przedstawiający empiryczny rozkład cechy.

| | | | | | | | | | |
|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|
| 3,9 | 5,8 | 5,5 | 4,6 | 6,1 | 4,8 | 5,8 | 4,1 | 4,5 | 4,9 |
| 5,2 | 5,3 | 6,2 | 6 | 5,7 | 4,5 | 4,1 | 2,4 | 4,7 | 4,4 |
| 3,9 | 4,9 | 4,2 | 3,6 | 4,1 | 3,5 | 8 | 4,4 | 7,7 | 8,2 |

Obliczone statystyki umieść w tabeli.

| Charakterystyki próby | Stężenie fluoru w powietrzu w mg/m³ |
|-------------------------------|---|
| \bar{x} (średnia) | |
| m_e (mediana) | |
| m_o (moda) | |
| x_{\min} (minimum) | |
| x_{\max} (maximum) | |
| R (rozstęp) | |
| s (odchylenie standardowe) | |
| v (współczynnik zmienności) | |
| $(\bar{x} - s, \bar{x} + s)$ | |

W celu obliczenia większości tych miar wpisujemy dane do jednej kolumny (zmiennej) oraz nadajemy nazwę zmiennej (klikając nagłówek dwa razy) do arkusza pakietu STATISTICA (patrz rysunek 1).

Następnie postępujemy według schematu: **STATYSTYKA → STATYSTYKI PODSTAWOWE I TABELLE → STATYSTYKI OPISOWE → OK → wprowadzamy zmienną → klikamy w zakładkę WIĘCEJ → Zaznaczamy interesujące nas wielkości i klikamy PODSUMOWANIE**

Charakterystyka próby. Doświadczenia jednoczynnikowe – analiza wariancji i testy szczegółowe
Weryfikacja hipotez dotyczących jednorodności wielu wariancji rozkładów normalnych
Test nieparametryczny Kruskala- Wallisa

| | 1 stężenie fluoru |
|----|-------------------------|
| 1 | 3,9 |
| 2 | 5,8 |
| 3 | 5,5 |
| 4 | 4,6 |
| 5 | 6,1 |
| 6 | 4,8 |
| 7 | 5,8 |
| 8 | 4,1 |
| 9 | 4,5 |
| 10 | 4,9 |
| 11 | 5,2 |
| 12 | 5,3 |
| 13 | 6,2 |
| 14 | 6 |
| 15 | 5,7 |
| 16 | 4,5 |
| 17 | 4,1 |
| 18 | 2,4 |

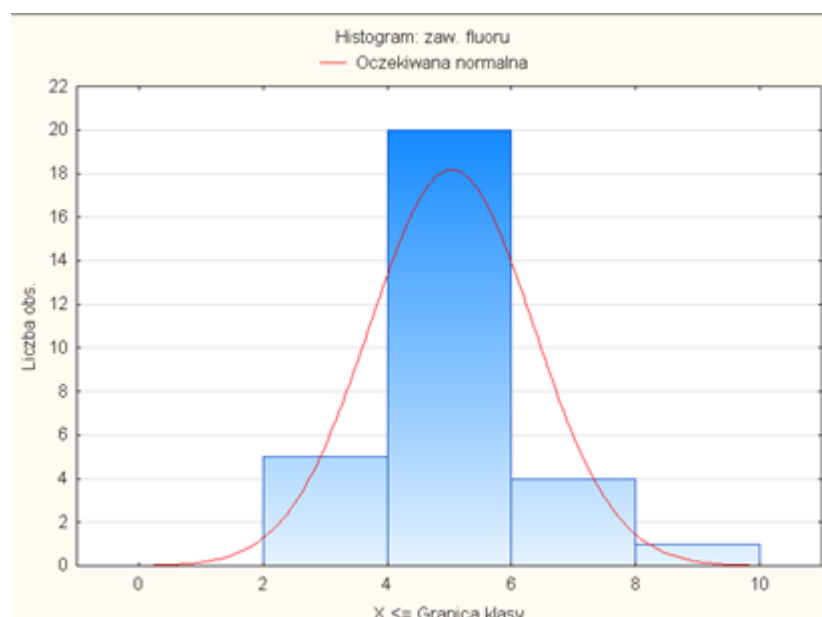
Do skróty i raportu zapisują nam się wyniki w postaci tabelki:

| Zmienna | Statystyki opisowe | | | | | | | | | | |
|-----------------|--------------------|---------|---------|------|---------------|---------|----------|---------|-----------|----------|----------|
| | Nważnych | Średnia | Mediana | Moda | Liczność Mody | Minimum | Maksimum | Rozstęp | Wariancja | Odch.std | Wsp.zmn. |
| stężenie fluoru | 30 | 5.0333 | 4.7500 | 4.10 | 3 | 2.40 | 8.20 | 5.80 | 1.7340 | 1.3168 | 26.16205 |

Aby sporządzić histogram postępujemy według schematu: **STATYSTYKA → STATYSTYKI PODSTAWOWE I TABELLE → STATYSTYKI OPISOWE → wprowadzamy zmienną → klikamy w zakładkę NORMALNOŚĆ (jak wyżej) → zmieniamy ewentualnie liczbę przedziałów ($\approx \sqrt{n}$) i wybieramy HISTOGRAM.**

Otrzymujemy:

Charakterystyka próby. Doświadczenia jednoczynnikowe – analiza wariancji i testy szczegółowe
Weryfikacja hipotez dotyczących jednorodności wielu wariancji rozkładów normalnych
Test nieparametryczny Kruskala- Wallisa

**Interpretacja:**

Zbadano stężenie fluoru w powietrzu w Luboniu w lipcu 2010 roku, uzyskując 30 obserwacji. Wartość średnia stężenia fluoru wyniosła $5,0333 \text{ mg/m}^3$. Mediana wyniosła $4,75 \text{ mg/m}^3$, co oznacza, że w próbie połowa obserwacji ma wartość mniejszą bądź równą $4,75 \text{ mg/m}^3$ i tyle samo obserwacji ma wartość większą bądź równą $4,75 \text{ mg/m}^3$. Wartość modalna (moda), czyli wartość obserwowana najczęściej wynosi $4,1 \text{ mg/m}^3$, przy czym wartość ta występuje trzy razy (liczność mody wynosi 3).

Z relacji $m_o < m_e < \bar{x}$ wynika, że rozkład empiryczny cechy jest prawostronnie asymetryczny (przypomnijmy, że dla zmiennej o rozkładzie normalnym wartości tych 3 miar położenia są jednakowe).

Najmniejszą obserwowaną wartością stężenia fluoru wśród 30 obserwacji było $2,4 \text{ mg/m}^3$, a największą obserwowaną wartością tego pestycydu było $8,2 \text{ mg/m}^3$. Rozstęp, czyli zakres zmienności obserwacji wyniósł $5,8 \text{ mg/m}^3$. Wariancja i odchylenie standardowe stężenia fluoru wynoszą odpowiednio $1,734 (\text{mg/m}^3)^2$ oraz $1,3168 \text{ mg/m}^3$. Stąd współczynnik zmienności wynosi około 26 % ($>10\%$), co oznacza, że obserwowana zmienna nie jest stabilna.

Zadanie 2. W ramach monitoringu wdrażania strategii rozwoju gminy, przeprowadzono badanie w wybranych losowo gospodarstwach rolniczych o powierzchni powyżej 30 ha zużycia energii elektrycznej w kilowatogodzinach na 1 ha użytków rolnych uzyskano następujące wyniki: 335; 196; 220; 113; 232; 205; 160; 263; 302; 221; 121; 245; 232; 115. Wyznacz i zinterpretuj średnią arytmetyczną, rozstęp, wariancję, odchylenie standardowe, współczynnik zmienności, medianę, modę, współczynnik skośności i spłaszczenia.

| Zmienna | Statystyki opisowe | | | | | | | | | |
|-----------------|--------------------|---------|--------|---------------|---------|-----------|----------|----------|----------|-----------|
| | Średnia | Mediana | Moda | Liczność Mody | Rozstęp | Wariancja | Odch.std | Wsp.zmn. | Skośność | Kurtoza |
| zużycie energii | 211,4286 | 220,50 | 232,00 | 2 | 222,00 | 4489,19 | 67,00 | 31,69 | 0,0281 | -0,419532 |

Zadanie 3. Otwórz plik temperatura umieszczony w katalogu DYDAKTYKA / Budka.

Scharakteryzuj temperaturę średnią dla miesiąca czerwca i dla lipca na podstawie zamieszczonych tam obserwacji z okresu 228 lat. Wykonaj histogramy rozkładu cechy.

$$\text{Odp. } \bar{x}_{cz} = 17,05833 ; \bar{x}_{lip} = 18,7663$$

Charakterystyka próby. Doświadczenia jednoczynnikowe – analiza wariancji i testy szczegółowe
Weryfikacja hipotez dotyczących jednorodności wielu wariancji rozkładów normalnych
Test nieparametryczny Kruskala- Wallisa

Zadanie 4. Elementem prowadzonej polityki sektorowej przemysłu, w rejonie składowiska odpadów Tarnów-Krzyż w ramach monitoringu zanieczyszczenia było badanie gleby. Pobrano 14 próbek do badań geochemicznych z trzech profili w celu zbadania stężenia pierwiastków w badanej glebie. Dane zebrano w poniższej tabeli. Korzystając z pakietu STATISTICA oblicz poznane miary położenia i rozrzutu dla otworu 1 (tło) oraz łącznie dla otworów 2 i 3 (oddziaływanie składowiska), także łącznie dla wszystkich próbek dla wszystkich oznaczanych pierwiastków.

| Symbol próbki | | | Bar | Chrom | Cynk | Kobalt | Mangan | Miedź | Nikiel | Olów | Rtęć | Stront | |
|---------------|---|-------------------------------|-----|-------|------|--------|--------|-------|--------|------|------|--------|-----|
| Nr otworu | 1 | Głębokość pobrania próbki (m) | 0,4 | 22 | 10 | 22 | 4 | 159 | 7,2 | 6 | 6 | 0,034 | 7 |
| | | | 0,8 | 25 | 13 | 23 | 2 | 42 | 10,9 | 8 | 6 | 0,033 | 9 |
| | | | 1,1 | 42 | 13 | 35 | 10 | 248 | 15,3 | 22 | 8 | 0,038 | 11 |
| | | | 2 | 59 | 18 | 65 | 9 | 541 | 21,7 | 29 | 12 | 0,066 | 98 |
| | | | 3 | 31 | 16 | 63 | 13 | 943 | 20,7 | 39 | 12 | 0,07 | 100 |
| | | | 3,8 | 33 | 14 | 57 | 9 | 954 | 19,2 | 29 | 11 | 0,059 | 98 |
| | 2 | | 0,4 | 32 | 10 | 28 | 6 | 493 | 9,4 | 7 | 8 | 0,029 | 7 |
| | | | 1 | 27 | 13 | 29 | 4 | 208 | 10,8 | 11 | 7 | 0,034 | 9 |
| | | | 1,7 | 32 | 11 | 31 | 5 | 241 | 13,2 | 17 | 7 | 0,026 | 41 |
| | | | 2,7 | 26 | 10 | 30 | 5 | 343 | 12,9 | 17 | 7 | 0,029 | 62 |
| | | | 3,5 | 29 | 11 | 37 | 7 | 472 | 15,1 | 22 | 8 | 0,037 | 67 |
| | 3 | | 0,8 | 63 | 19 | 65 | 14 | 944 | 19,6 | 31 | 14 | 0,078 | 14 |
| | | | 2,5 | 36 | 15 | 61 | 10 | 984 | 20,1 | 29 | 11 | 0,062 | 99 |
| | | | 3,6 | 40 | 13 | 62 | 10 | 902 | 17,3 | 31 | 11 | 0,061 | 94 |

Dane pochodzą z rozprawy doktorskiej p. K. Sobiak pod tytułem „Badanie wpływu składowisk odpadów na środowisko gruntowo-wodne na przykładzie wybranych obiektów zlokalizowanych w obrębie zlewni Dunajca.”

Danych jest v populacji normalnych $N(\mu_i; \sigma_i)$, $i=1,2,\dots,v$. Z każdej populacji wylosowano próbkę n_i elementową. Formuluje się hipotezę:

$$H_0 : \sigma_1^2 = \sigma_2^2 = \dots = \sigma_v^2$$

$$H_1 : \sim H_0.$$

$$\text{Test Bartletta : } X^2 = \frac{(n-v) \ln \left[\frac{1}{n-v} \sum_{i=1}^v (n_i-1) \hat{s}_i^2 \right] - \sum_{i=1}^v (n_i-1) \ln [\hat{s}_i^2]}{1 + \frac{1}{3(v-1)} \left[\sum_{i=1}^v \left(\frac{1}{n_i-1} \right) - \frac{1}{n-v} \right]}$$

Jeżeli $X^2 > X_{\alpha, v-1}^2$ hipotezę H_0 odrzucamy.

UKŁAD CAŁKOWICIE LOSOWY

Model obserwacji (model analizy wariancji) w doświadczeniu jednoczynnikowym o układzie całkowicie losowym

$$y_{ij} = \mu + \alpha_i + \varepsilon_{ij} \text{ (wyraz wolny + efekt obiektowy + błąd doświadczalny) ,}$$

Charakterystyka próby. Doświadczenia jednoczynnikowe – analiza wariancji i testy szczegółowe
Weryfikacja hipotez dotyczących jednorodności wielu wariancji rozkładów normalnych
Test nieparametryczny Kruskala- Wallisa

gdzie $i=1,2,\dots,v$, $j=1,2,\dots,r_i$ oraz $\sum_{i=1}^v \alpha_i = 0$, przy czym spełnione są założenia, które zapisujemy krótko w

postaci $y_{ij} \sim N(\mu + \alpha_i; \sigma)$ lub równoważnie w postaci $\varepsilon_{ij} \sim N(0; \sigma)$.

Stawiamy hipotezę :

$$H_0: \mu_1 = \mu_2 = \dots = \mu_v$$

$$H_1: \sim H_0$$

Przeprowadzamy analizę wariancji (układ całkowicie losowy), wyznaczamy statystykę F :

| Źródła zmienności | Stopnie swobody | Sumy kwadratów SS | Średnie kwadraty MS | F |
|-------------------|-----------------|-------------------|---------------------|-------|
| Obiekty | $v-1$ | SS_O | MS_O | F_0 |
| Błąd | $n-v$ | SS_E | MS_E | |
| Całkowita | $n-1$ | SS_C | | |

Wzory na końcu materiałów. Jeśli $F_0 > F_{\alpha; v-1; n-v}$ to hipotezę H_0 odrzucamy.

Po odrzuceniu hipotezy H_0 stawiamy hipotezy szczegółowe dla $i, i'=1, \dots, v$, $i \neq i'$:

$$H_{0ii'}: \mu_i - \mu_{i'} = 0$$

$$H_{1ii'}: \sim H_{0ii'}$$

Weryfikację tych hipotez przeprowadzamy:

- testem wielokrotnym **Tukeya** jako testem najbardziej polecany do porównywania par średnich jego celem jest ustalenie, które grupy w próbce różnią się.
- testem jednokrotnym **Fishera**, stosowanym najczęściej tylko do wybranych porównań średnich.

(wzory na końcu materiału)

Zadanie 5 Ze względu na szczególną rolę uzdrowiskowo-wypoczynkową pięciu nadmorskich miast, porównywano powierzchnię zieleni ogólnodostępnej (w ha) według uchwalonych planów miejscowych w miastach A, B, C, D i E na przestrzeni kilku lat . Przeprowadzono odczyty w tych latach i otrzymano:

| | | | | |
|---|-----|-----|-----|-----|
| A | 9,5 | 9,0 | 9,6 | 9,5 |
| B | 9,0 | 9,0 | 9,2 | |
| C | 8,9 | 8,7 | 8,8 | |
| D | 8,8 | 9,2 | 9,0 | 9,0 |
| E | 8,5 | 8,6 | 8,5 | 8,7 |

Przy prawdziwości założenia analizy wariancji (założenia o rozkładzie normalnym zmiennej obserwowanej) :

- Na poziomie istotności $\alpha=0,01$ zweryfikować hipotezę o jednorodności wariancji dla powierzchni zielonych w badanych miastach. Zastosować test Bartletta.
- Przy prawdziwości założeń analizy wariancji na poziomie istotności $\alpha=0,01$ zweryfikować hipotezę ogólną o braku istotnych różnic między rzeczywistą średnią powierzchnią zieleni ogólnodostępnej w badanych miast na przestrzeni interesujących lat.
- Wykorzystać test **Fishera** do porównań średnich powierzchni zielonych parami. Postawić i zweryfikować odpowiednie hipotezy szczegółowe. Przyjąć poziom istotności $\alpha = 0,01$.

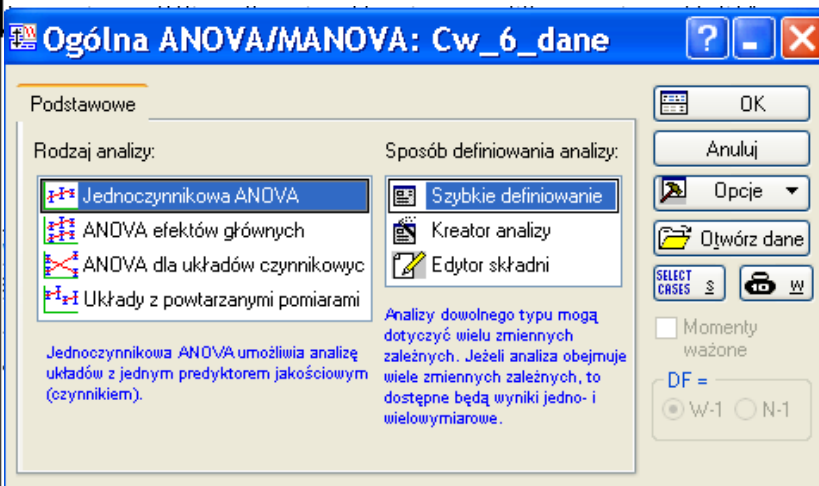
Rozwiązanie:

Wypełniamy arkusz danych

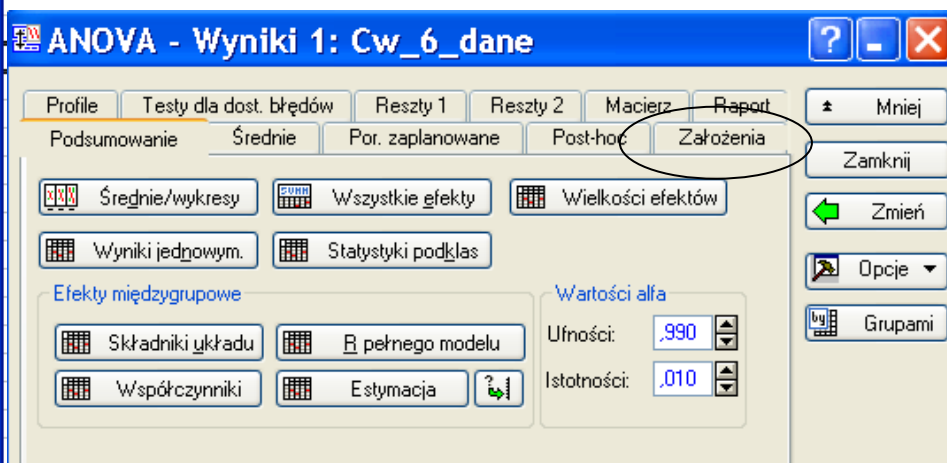
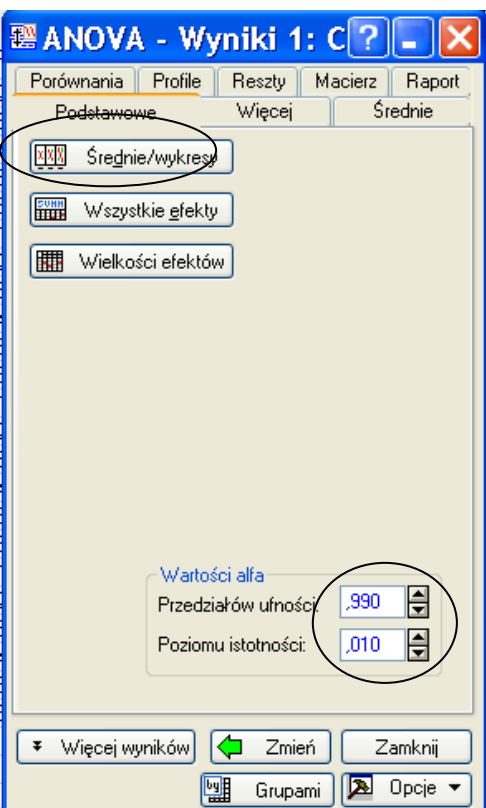
Za pomocą programu STATISTICA wybieramy : STATYSTYKA → ANOVA → JEDNOCZYNNIKOWA ANOVA → SZYBKIE DEFINIOWANIE → OK

Charakterystyka próby. Doświadczenia jednoczynnikowe – analiza wariancji i testy szczegółowe
Weryfikacja hipotez dotyczących jednorodności wielu wariancji rozkładów normalnych
Test nieparametryczny Kruskala- Wallisa

| | 3 obiekty (miasta) | 4 pow. ziel. ha |
|----|--------------------------|-----------------------|
| 1 | A | 9,5 |
| 2 | A | 9 |
| 3 | A | 9,6 |
| 4 | A | 9,5 |
| 5 | B | 9 |
| 6 | B | 9 |
| 7 | B | 9,2 |
| 8 | C | 8,9 |
| 9 | C | 8,7 |
| 10 | C | 8,8 |
| 11 | D | 8,8 |
| 12 | D | 9,2 |
| 13 | D | 9 |
| 14 | D | 9 |
| 15 | E | 8,5 |
| 16 | E | 8,6 |
| 17 | E | 8,5 |
| 18 | E | 8,7 |



→ ustalamy zmienne w obrębie pola **Listy zmiennych zależnych** zaznaczamy zmienną obserwacji, czyli **powierzchnia zieleni**, a w polu **Predyktor jakościowy (czynniki)** wybieramy zmienną **obiekty** i akceptujemy **OK**→**OK**. Pojawia się okno **ANOVA-wyniki 1**. Ustalamy w nim poziom istotności 0,01, ufności 0,99.



a) Sprawdzanie założenia o jednorodności wariancji :

Stawiamy hipotezy: zerową i alternatywną

$H_0: \sigma_1^2 = \sigma_2^2 = \sigma_3^2 = \sigma_4^2 = \sigma_5^2$ rzeczywista wariancja powierzchni

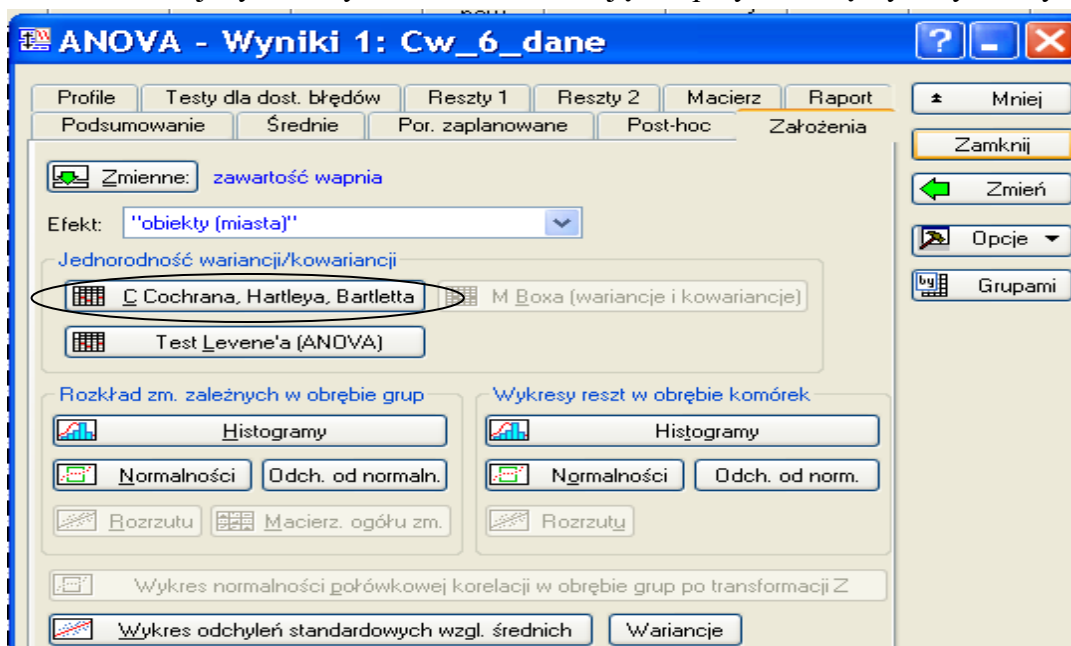
zielonej w badanych miast **nie** różni się między sobą istotnie

$H_1: \sim H_0$ co najmniej dwie wariancje dla powierzchni zielonych w badanych miast **różnią się** między sobą istotnie

Za pomocą programu STATISTICA

Charakterystyka próby. Doświadczenia jednoczynnikowe – analiza wariancji i testy szczegółowe
Weryfikacja hipotez dotyczących jednorodności wielu wariancji rozkładów normalnych
Test nieparametryczny Kruskala- Wallisa

W oknie ANOVA – Wyniki 1 → wybieramy zakładkę **WIĘCEJ WYNIKÓW** → następnie zakładkę **ZAŁOŻENIA** i w niej wybieramy test Bartletta, klikając na przycisk między innymi z tym testem.



Otrzymujemy:

| Testy jednorodności wariancji (Zadanie 6-1.sta) | | | | | |
|---|--------------------|---------------|---------------------|---------|----------|
| Efekt: "obiekty (miasta)" | | | | | |
| | Hartleya F-maks | Cochrana C | Bartlett Chi-kw. | a df | p |
| zawartość wapnia | 8,000000 | 0,553459 | 3,886263 | 4 | 0,421617 |

Decyzja i wniosek:

Ponieważ $p = 0,421617 > \alpha = 0,01$, to na poziomie istotności 0.01 nie mamy podstaw do odrzucenia hipotezy zerowej, orzekającej o jednorodności wariancji.

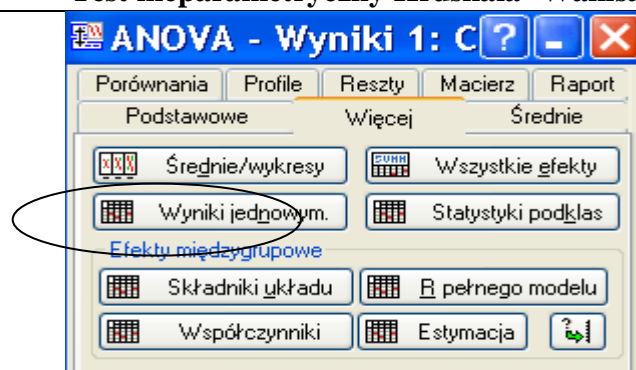
b) Stawiamy hipotezy: zerową i alternatywną

$H_0: \mu_1 = \mu_2 = \mu_3 = \mu_4 = \mu_5$ rzeczywiste średnie powierzchnie zielone w badanych miast **nie** różnią się między sobą istotnie

$H_1: \sim H_0$ co najmniej dwie średnie powierzchnie zielone w badanych miastach **różnią się** między sobą istotnie

Za pomocą programu STATISTICA : Ponownie wracamy do początkowego okna ANOVA – Wyniki 1 (klikając przycisk **MNIEJ**) można w nim otworzyć kartę **WIĘCEJ**

Charakterystyka próby. Doświadczenia jednoczynnikowe – analiza wariancji i testy szczegółowe
Weryfikacja hipotez dotyczących jednorodności wielu wariancji rozkładów normalnych
Test nieparametryczny Kruskala- Wallisa



→ klikając w niej przycisk **WYNIKI JEDNOWYMIAROWE**. Otrzymamy tabelę analizy wariancji
Tabela analizy wariancji ANOVA

| Wyniki jednowymiarowe dla każdej ZZ (Zadanie 6-1.sta) Parametryzacja z sigma-ograniczeniami Dekompozycja efektywnych hipotez | | | | | |
|--|-----------------|-----------------------|-----------------------|----------------------|----------------------|
| Efekt | Stopnie swobody | pow. ziel. w ha SS | pow. ziel. w ha MS | pow. ziel. w ha F | pow. ziel. w ha p |
| Wyraz wolny | 1 | 1419,371 | 1419,371 | 49314,44 | 0,000000 |
| obiekty (miasta) | 4 | 1,482 | 0,370 | 12,87 | 0,000186 |
| Błąd | 13 | 0,374 | 0,029 | | |
| Ogół | 17 | 1,856 | | | |

Decyzja:

Ponieważ prawdopodobieństwo $p = 0,000186 < \alpha = 0,01$, to na poziomie istotności $\alpha = 0,01$ odrzucamy hipotezę H_0 na korzyść hipotezy H_1 .

Wniosek:

Na poziomie istotności 0.01 stwierdzamy istotne zróżnicowanie rzeczywistych średnich powierzchni zielonych w badanych miastach.

c) Stawiamy hipotezy szczegółowe:

$$H_{0ii'}: \mu_i - \mu_{i'} = 0 \quad i, i' = 1, 2, 3, 4, 5$$

$$H_{1ii'}: \sim H_{0ii'} \quad i \neq i'$$

W celu wykonania dalszej analizy szczegółowej po analizie wariancji wracamy znów do okna **ANOVA – Wyniki 1** → **WIĘCEJ WYNIKÓW**, a następnie klikamy opcję **POST-HOC**. W polu **Pokaż** zaznaczamy **Istotne różnice** i wybieramy **TEST NIR FISHERA**.

Charakterystyka próby. Doświadczenia jednoczynnikowe – analiza wariancji i testy szczegółowe
Weryfikacja hipotez dotyczących jednorodności wielu wariancji rozkładów normalnych
Test nieparametryczny Kruskala- Wallisa

Otrzymujemy tabelę, w której

prawdopodobieństwa p mniejsze od $\alpha = 0,01$ oznaczają odrzucenie hipotez zerowych szczegółowych.

| Test NIR; zmienna zawartość wapnia (Zadanie 6-1.sta) | | | | | | |
|--|------------------|----------|----------|----------|----------|----------|
| Prawdopodobieństwa dla testów post-hoc | | | | | | |
| Błąd: MS międzygrupowe = ,02878, df = 13,000 | | | | | | |
| Nr podkl. | obiekty (miasta) | {1} | {2} | {3} | {4} | {5} |
| 1 | A | 9,4000 | 0,023183 | 0,000471 | 0,005380 | 0,000011 |
| 2 | B | 0,023183 | | 0,076377 | 0,615534 | 0,002231 |
| 3 | C | 0,000471 | 0,076377 | | 0,146692 | 0,106105 |
| 4 | D | 0,005380 | 0,615534 | 0,146692 | | 0,003606 |
| 5 | E | 0,000011 | 0,002231 | 0,106105 | 0,003606 | |

Decyzje:

Na poziomie istotności $\alpha = 0,01$, na podstawie testu Fishera, odrzucamy hipotezy szczegółowe dla par miast: A-C (bo $p=0,000471 < \alpha = 0,01$), A-D (bo $p=0,005380 < \alpha = 0,01$), A-E (bo $p=0,000011 < \alpha = 0,01$), B-E (bo $p=0,002231 < \alpha = 0,01$), D-E (bo $p=0,003606 < \alpha = 0,01$).

Wnioski:

Na poziomie istotności 0,01 stwierdzamy, że prawdziwe średnie powierzchnie zielone wypisanych powyżej par miast różnią się między sobą istotnie.

Charakterystyka próby. Doświadczenia jednoczynnikowe – analiza wariancji i testy szczegółowe
Weryfikacja hipotez dotyczących jednorodności wielu wariancji rozkładów normalnych
Test nieparametryczny Kruskala- Wallisa

TEST KRUSKALA-WALLISA jest jedną z najpopularniejszych alternatyw dla jednoczynnikowej analizy wariancji. Przeprowadzany jest w przypadku, gdy zostały złamane założenia ANOVA bądź gdy charakter naszych zmiennych nie pozwala na wykorzystanie analizy wariancji.

Weryfikujemy hipotezy:

H_0 : Rozkłady dla k populacji są takie same

H_1 : Nie wszystkie rozkłady są takie same

Wszystkim obserwacjom zmiennej losowej X uszeregowanym niemalejąco nadajemy rangi, czyli kolejne numery od 1 do n (jednakowym wartościom obserwacji przypisujemy liczbę będącą średnią arytmetyczną rang, które kolejno miały następować. Dla każdej próbki obliczamy sumy rang $T_i, i=1, 2, \dots, v$.

Wyznaczamy wartość statystyki:

$$X^2 = \frac{12}{n(n+1)} \sum_{i=1}^v \frac{T_i^2}{n_i} - 3(n+1).$$

Jeżeli H_0 jest prawdziwa to powyższa statystyka ma asymptotyczny rozkład chi-kwadrat o $(v-1)$ stopniach swobody.

Przyjmujemy poziom istotności α i odczytujemy wartość krytyczną

$X_{\alpha, v-1}^2$. Jeżeli $X^2 > X_{\alpha, v-1}^2$ hipotezę H_0 odrzucamy.

Zadanie 6. Inspektor do spraw polityki przestrzennej i planowania miejscowego, zlecił przeprowadzenie analiz w celu sprawdzenie, czy preferencje studentów różnych kierunków (Gospodarki Przestrzennej, Ochrony Środowiska, Ekonomii, Medycyny) do zamieszkania w małej miejscowości różnią się istotnie na poziomie istotności 0,01. Wyniki ankiet przeprowadzonych pośród 10 studentów każdego kierunku podano w umownej skali sumarycznej.

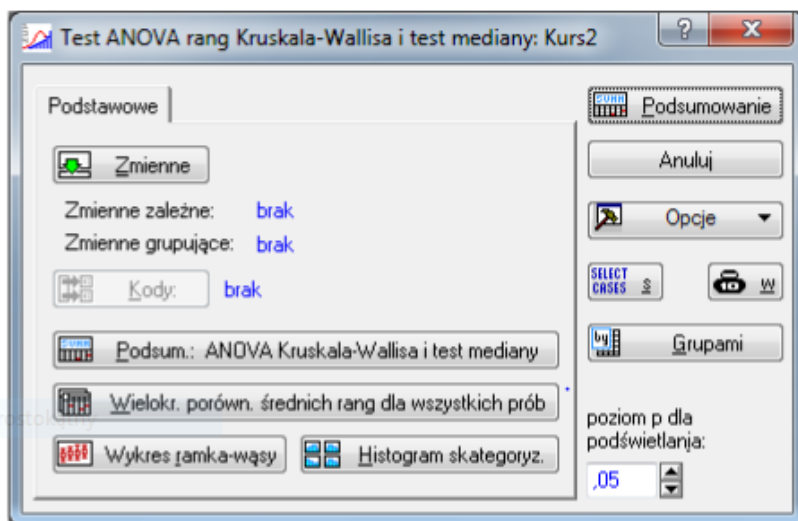
| Grupa ankietowanych | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 |
|--------------------------|----|----|----|----|----|----|----|----|----|----|
| Gospodarki Przestrzennej | 38 | 39 | 48 | 31 | 43 | 37 | 38 | 47 | 33 | 44 |
| Ochrony Środowiska | 56 | 48 | 47 | 54 | 50 | 55 | 48 | 46 | 53 | 49 |
| Ekonomii | 44 | 49 | 40 | 40 | 49 | 45 | 48 | 41 | 39 | 50 |
| Medycyny | 44 | 45 | 48 | 53 | 52 | 43 | 44 | 49 | 52 | 50 |

Z racji, że porównywanych grup było więcej niż 2 (4 kierunki studiów) a zmienna zależna (punktacja) była mierzona na skali porządkowej przeprowadzono test Kruskala-Wallisa, aby porównać ze sobą grupy studentów pod względem preferencji zamieszkania w małej miejscowości.

W celu przeprowadzenia analizy, należy wprowadzić dane do arkusza:

Charakterystyka próby. Doświadczenia jednoczynnikowe – analiza wariancji i testy szczegółowe
Weryfikacja hipotez dotyczących jednorodności wielu wariancji rozkładów normalnych
Test nieparametryczny Kruskala- Wallisa

| | 1 | 2 |
|----|-------------------------|-----------|
| | Kierunek studiów | Punktacja |
| 1 | Gospodarki Przestrzenna | 38 |
| 2 | Gospodarki Przestrzenna | 39 |
| 3 | Gospodarki Przestrzenna | 48 |
| 4 | Gospodarki Przestrzenna | 31 |
| 5 | Gospodarki Przestrzenna | 43 |
| 6 | Gospodarki Przestrzenna | 37 |
| 7 | Gospodarki Przestrzenna | 38 |
| 8 | Gospodarki Przestrzenna | 47 |
| 9 | Gospodarki Przestrzenna | 33 |
| 10 | Gospodarki Przestrzenna | 44 |
| 11 | Ochrona Środowiska | 56 |
| 12 | Ochrona Środowiska | 48 |



Z menu **Statystyka** opcję **Statystyki nieparametryczne**. Następnie w otwierającym się oknie wybieramy opcję **Porównanie wielu prób niezależnych (grup)**. Po kliknięciu na przycisku **OK** otworzy się okno **Test ANOVA rang Kruskala-Wallisa i test mediany** (rysunek powyżej).

Klikając przycisk **Podsumowanie**. **ANOVA Kruskala-Wallisa** i test mediany otrzymujemy dwa arkusze wyników. Nas interesuje ten dotyczący nieparametrycznej analizy wariancji.

| | | | | |
|--------------------------------|--|--------------------------------|----------------------|----------------------|
| | Wartość p dla porównań wielokrotnych (dwustronnych); Punktacja (Arkusz2) | | | |
| | Zmienna niezależna (grupująca): Kierunek studiów | | | |
| | Test Kruskala-Wallisa: $H(3, N=40)=18,11213$ $p=,0004$ | | | |
| Zależna: Punktacja | Gospodarki Przestrzenna R:9,2000 | Ochrona Środowiska R:30,150 | Ekonomia R:17,850 | Medycyna R:24,800 |
| Gospodarki Przestrzenna | | 0,000369 | 0,588142 | 0,017078 |
| Ochrona Środowiska | 0,000369 | | 0,111839 | 1,000000 |
| Ekonomia | 0,588142 | 0,111839 | | 1,000000 |
| Medycyna | 0,017078 | 1,000000 | 1,000000 | |

Decyzje:

Na poziomie istotności $\alpha = 0,05$, na podstawie testu Kruskala-Wallisa odrzucamy hipotezę zerową o braku istotnych różnic pomiędzy preferencjami studentów rozważanych kierunków $H(3, N=40)=18,11213$ (bo $p=0,0004 < \alpha = 0,05$). Podane wartości p w tabeli, takie, że $p < \alpha = 0,05$ wskazują na pary kierunków, studiów po których preferencje studentów różnią się istotnie.

Wnioski:

Na poziomie istotności 0,05 stwierdzamy, że preferencje studentów z wybranych kierunków różnią się istotnie. Na podstawie testu porównań wielokrotnych stwierdzono różnice w preferencjach dla kierunków: Gospodarka Przestrzenna-Ochrona Środowiska (bo $p=0,000369 < \alpha = 0,05$), Gospodarka Przestrzenna-Medycyna (bo $p=0,017078 < \alpha = 0,05$).

Charakterystyka próby. Doświadczenia jednoczynnikowe – analiza wariancji i testy szczegółowe
Weryfikacja hipotez dotyczących jednorodności wielu wariancji rozkładów normalnych
Test nieparametryczny Kruskala- Wallisa

Zadanie 7 Porównywano zawartość magnezu (w mg/l) w wodach mineralnych czterech rodzajów (obiektów) dostępnych na polskim rynku. Otrzymane obserwacje zapisano w tabeli (dane pobierz z pliku cw2.sta).

| Muszynianka | Muszynianka plus | Piwniczanka | Galicjanka |
|-------------|------------------|-------------|------------|
| * | * | * | * |
| * | * | * | * |

Przy prawdziwości założeń analizy wariancji

- a) Na poziomie istotności $\alpha=0,01$ zweryfikować hipotezę ogólną o braku istotnych różnic między rzeczywistymi średnimi zawartościami magnezu w badanych wodach mineralnych.
b) Na poziomie istotności $\alpha=0,01$ zweryfikować hipotezę o jednorodności wariancji zawartości magnezu w badanych wodach. Zastosować test Bartletta.
c) Wykorzystać test **Tukeya** do porównań średnich zawartości magnezu w wodach mineralnych parami. W tym celu postawić i zweryfikować odpowiednie hipotezy szczegółowe. Przyjąć $\alpha = 0,01$.

Odp. a) $p = 0,0000 < \alpha = 0,01$; b) $p = 0,038777 > \alpha = 0,01$;

Zadanie 8 Podczas zajęć laboratoryjnych 4-osobowa grupa studentek (S1, S2, S3, S4) uczyła się ustalać kwasowość gleby mierzonej współczynnikiem pH. Każda studentka pobrała losowo 23 próbki gleby i poddała je badaniom chemicznym. Obserwacje pobierz z pliku cw2.sta.

Przy prawdziwości założeń analizy wariancji :

- a) Na poziomie istotności $\alpha = 0,02$ zweryfikować hipotezę ogólną o braku różnic między średnimi kwasowościami gleby oznaczonymi przez poszczególne studentki.
b) Wykorzystać test **Tukeya** do porównań wielokrotnych. W tym celu utworzyć grupy jednorodne średnich na poziomie istotności $\alpha = 0,02$.
c) Wykonać wykres średnich

Odp. a) $p = 0,0000$; b) grupy: (S2, S3), (S1, S4); c) graficzna prezentacja średnich potwierdza ich różnicowanie, bo wyznaczone 98 % przedziały ufności są rozłączne dla co najmniej jednej pary obiektów.

Zadanie 9 W ramach monitoringu zanieczyszczenia powietrza benzenem w województwie małopolskim zebrano dane dotyczące stężenia benzenu dla 6 miejscowości tego województwa. W każdej miejscowości było 12 stanowisk pomiarowych, dla których obliczono średnie dobowe (w $\mu\text{g}/\text{m}^3$). Dane te znajdują się w pliku cw2.sta.

- a) Na poziomie istotności $\alpha=0,05$ zweryfikować hipotezę ogólną o braku istotnych różnic między rzeczywistym poziomem średniodobowego stężenia benzenu w poszczególnych miejscowościach województwa małopolskiego.
b) Wykorzystać test Fishera do porównań rzeczywistych średnich stężeń benzenu w badanych miejscowościach. W tym celu postawić i zweryfikować odpowiednie hipotezy szczegółowe. Przyjąć poziom istotności $\alpha = 0,05$.

Odp. a) $p = 0,001337$;

b) istotne różnice M1 z M3, M1 z M4, M1 z M5, M1 z M6, M2 z M6, M2 z M3.

Zadanie 10 Dokonywano pomiarów zanieczyszczenia powietrza (emisji) na terenie Poznania. Oznaczano m.in. zawartość dwutlenku siarki w $\mu\text{g}/\text{m}^3/\text{miesiąc}$. Dla poszczególnych dzielnic otrzymano obserwacje:

| | | | | | |
|--------------|-----|-----|-----|-----|-----|
| Stare Miasto | 3,9 | 4,0 | 4,3 | 4,0 | |
| Nowe Miasto | 3,2 | 3,4 | 3,0 | 3,4 | |
| Wilda | 4,5 | 4,6 | 5,2 | | |
| Jeżyce | 2,5 | 2,6 | 2,5 | 2,8 | |
| Grunwald | 3,8 | 3,7 | 4,0 | 3,9 | 4,3 |

Charakterystyka próby. Doświadczenia jednoczynnikowe – analiza wariancji i testy szczegółowe
Weryfikacja hipotez dotyczących jednorodności wielu wariancji rozkładów normalnych
Test nieparametryczny Kruskala- Wallisa

a) Na poziomie istotności $\alpha=0,01$ zweryfikować hipotezę ogólną o braku istotnych różnic między rzeczywistymi średnimi zawartościami dwutlenku siarki w dzielnicach Poznania.

b) Wykorzystać test Fishera do porównań średnich zawartości dwutlenku siarki. W tym celu postawić i zweryfikować odpowiednie hipotezy szczegółowe. Przyjąć poziom istotności $\alpha=0,01$.

Odp. a) $p=0,000000$; b) nie odrzucamy hipotezy dla porównania Stare Miasto - Grunwald

Zadanie 9 Badając wpływ składowania odpadów na glebę pobrano 14 próbek gleby do badań geochemicznych z trzech profili. Określono w nich między innymi stężenie rtęci. Otrzymując obserwacje:

| | | | | | | |
|---------|-------|-------|-------|-------|-------|-------|
| Otwór 1 | 0,034 | 0,033 | 0,038 | 0,066 | 0,07 | 0,059 |
| Otwór 2 | 0,029 | 0,034 | 0,026 | 0,029 | 0,037 | |
| Otwór 3 | 0,078 | 0,062 | 0,061 | | | |

Przyjmując $\alpha=0,05$ i założenie o normalności rozkładu

a) Sprawdzić czy spełnione jest założenie o jednorodności wariancji.

b) Odpowiedzieć czy badane profile (otwory) różniły się pod względem zawartości badanego pierwiastka.

c) Jeżeli jest to uzasadnione wykorzystać test Tukeya do porównań wielokrotnych w tym celu utworzyć grupy jednorodne.

Odp. a) $p=0,066857$; b) $p=0,006437$; c)) grupy: (otwór 2, otwór 1), (otwór 1, otwór 3).

Zadanie 11 Obserwowano dobowy przybór odpadów (w m³) na terenie kilku gmin w ciągu 5 dni. Otrzymano dane:

| Gmina 1 | Gmina 2 | Gmina 3 | Gmina 4 |
|---------|---------|---------|---------|
| 6,5 | 8,0 | 8,0 | 5,3 |
| 6,7 | 8,4 | 9,4 | 6,4 |
| 7,2 | 9,2 | 7,8 | 7,2 |
| 6,4 | 8,3 | 8,3 | 6,7 |
| 6,9 | 7,9 | 8,5 | 6,9 |

a) Na poziomie istotności $\alpha=0,01$ zweryfikować hipotezę ogólną o braku istotnych różnic między rzeczywistymi średnimi przyborami odpadów w badanych gminach.

b) Wykorzystać test Tukeya do porównań średnich dobowych przyborów odpadów. W tym celu postawić i zweryfikować odpowiednie hipotezy szczegółowe. Przyjąć poziom istotności $\alpha=0,01$.

Odp. a) $p=0,000042$.

Zadanie 12 Poniższe dane dotyczą frekwencji (w procentach) w wyborach prezydenckich z wybranych komisji wyborczych w trzech miastach wojewódzkich:

Wrocław: 38,5; 40,8; 41,7; 41,2; 37,9; 38,3; 42; 39,8; 43,1; 42,6

Warszawa: 38,9; 43,1; 40,4; 41,8; 42,39; 43,7; 40; 39,7; 43; 43,1

Poznań: 43,9; 44,2; 45,2; 44,6; 42,5; 43,4; 44,8; 42,8; 43,1; 44,8; 45

Na poziomie istotności $\alpha=0,05$ zweryfikować hipotezę, że rozkłady frekwencji we wszystkich miastach są jednakowe przy alternatywie, że się różnią. Zastosować test **Kruskala-Wallisa**.

Charakterystyka próby. Doświadczenia jednoczynnikowe – analiza wariancji i testy szczegółowe
Weryfikacja hipotez dotyczących jednorodności wielu wariancji rozkładów normalnych
Test nieparametryczny Kruskala- Wallisa

Wzory 1 : TESTY PARAMETRYCZNE

| Analiza wariancji - UKŁAD CAŁKOWICIE LOSOWY | | |
|---|--|--|
| Sumy kwadratów SS i średnie kwadraty MS | $SS_C = \sum_{i=1}^v \sum_{j=1}^{r_i} x_{ij}^2 - \frac{(\sum_{i=1}^v \sum_{j=1}^{r_i} x_{ij})^2}{n}, \quad SS_O = \sum_{i=1}^v \frac{(\sum_{j=1}^{r_i} x_{ij})^2}{r_i} - \frac{(\sum_{i=1}^v \sum_{j=1}^{r_i} x_{ij})^2}{n},$ $SS_E = SS_C - SS_O$ | $MS_O = \frac{SS_O}{v-1}$ $MS_E = \frac{SS_E}{n-v}$ |
| Hipoteza ogólna - test dla porównania wielu obiektów - test Fishera – Snedecora | | |
| $H_0: \mu_1 = \mu_2 = \dots = \mu_v$ $H_1: \sim H_0$ | $F_0 = \frac{MS_O}{MS_E}$ | Obszar krytyczny $F_0 > F_{\alpha; v-1; n-v}$ |
| Hipotezy szczegółowe - test dla różnicy średnich : | | |
| test Tukeya | | |
| $H_{0ii'}: \mu_i - \mu_{i'} = 0$ $H_{1ii'}: \sim H_{0ii'}$ | gdy $ \bar{x}_i - \bar{x}_{i'} > NIR^T$ H_0 odrzucamy | Najmniejsza istotna różnica $NIR^T = \sqrt{\frac{MS_E}{r}} \cdot q_{\alpha, v, v_E}$ |
| test Fishera | | |
| $H_{0ii'}: \mu_i - \mu_{i'} = 0$ $H_{1ii'}: \sim H_{0ii'}$ | gdy $ \bar{x}_i - \bar{x}_{i'} > NIR^F$ H_0 odrzucamy | Najmniejsza istotna różnica $NIR^F = \sqrt{MS_E \left(\frac{1}{r_i} + \frac{1}{r_{i'}} \right)} \cdot t_{\alpha, v_E}$ |

Wzory 1 : TESTY NIEPARAMETRYCZNE

Hipotezy szczegółowe - test dla różnicy średnich :

Obliczamy średnie rang \bar{x}_i dla każdego obiektu (populacji), $i=1, 2, \dots, v$.

| test Chi - kwadrat | | |
|--|---|---|
| $H_{0ii'}: \mu_i - \mu_{i'} = 0$ $H_{1ii'}: \sim H_0$ | gdy $ \bar{x}_i - \bar{x}_{i'} > NIR^{chi}$ H_0 odrzucamy | Najmniejsza istotna różnica $NIR^{chi} = \sqrt{X_{\alpha, v-1}^2 \cdot \frac{n(n+1)}{12} \cdot \left(\frac{1}{n_i} + \frac{1}{n_{i'}} \right)}$ |